# Statistik 02. Deskriptive Statistik

#### Roland Schäfer

Institut für Germanistische Sprachwissenschaft Friedrich-Schiller-Universität Jena

stets aktuelle Fassungen: https://github.com/rsling/VL-Statistik

#### Inhalt

- 1 Motivation
- 2 Skalenniveau
- 3 Zentraltendenz

- 4 Empirische Verteilungen und Dispersion
- Bivariate Statistiken
- 6 Standardfehler und Konfidenzintervalle
- Nächste Woche | Überblick

# Übersicht

• Deskriptive Statistik als Aggregation von Daten

# Übersicht

- Deskriptive Statistik als Aggregation von Daten
- Verteilungen in Stichproben und Grundgesamtheiten:

- Deskriptive Statistik als Aggregation von Daten
- Verteilungen in Stichproben und Grundgesamtheiten:
  - Zentralmaße

- Deskriptive Statistik als Aggregation von Daten
- Verteilungen in Stichproben und Grundgesamtheiten:
  - Zentralmaße
  - Streuung (Varianz)

- Deskriptive Statistik als Aggregation von Daten
- Verteilungen in Stichproben und Grundgesamtheiten:
  - Zentralmaße
  - Streuung (Varianz)
- Theoretische vs. empirische Verteilungen

- Deskriptive Statistik als Aggregation von Daten
- Verteilungen in Stichproben und Grundgesamtheiten:
  - Zentralmaße
  - Streuung (Varianz)
- Theoretische vs. empirische Verteilungen
- Konfidenzintervalle | Genauigkeiten von Schätzungen?

#### Literatur

- Google, Stackoverflow usw.
- Gravetter & Wallnau (2007)
   Achtung! Vermittelt eine falsche Philosophie bei Anwendung der Tests!
- Bortz & Schuster (2010)

# Motivation

• Mit unbewaffnetem Auge auf Daten zu blicken, ist meistens zwecklos.

- Mit unbewaffnetem Auge auf Daten zu blicken, ist meistens zwecklos.
- In Zahlen sehen Menschen nur schlecht Tendenzen und Zusammanhänge.

- Mit unbewaffnetem Auge auf Daten zu blicken, ist meistens zwecklos.
- In Zahlen sehen Menschen nur schlecht Tendenzen und Zusammanhänge.
- Deskriptive Statistik

- Mit unbewaffnetem Auge auf Daten zu blicken, ist meistens zwecklos.
- In Zahlen sehen Menschen nur schlecht Tendenzen und Zusammanhänge.
- Deskriptive Statistik
  - Zusammenfassen

- Mit unbewaffnetem Auge auf Daten zu blicken, ist meistens zwecklos.
- In Zahlen sehen Menschen nur schlecht Tendenzen und Zusammanhänge.
- Deskriptive Statistik
  - Zusammenfassen
  - Gruppieren

- Mit unbewaffnetem Auge auf Daten zu blicken, ist meistens zwecklos.
- In Zahlen sehen Menschen nur schlecht Tendenzen und Zusammanhänge.
- Deskriptive Statistik
  - Zusammenfassen
  - Gruppieren
  - Visualisieren

• Definition der Grundgesamtheit

- Definition der Grundgesamtheit
- Stichprobengröße (n)

- Definition der Grundgesamtheit
- Stichprobengröße (n)
  - ▶ 200 Sätze aus dem Korpus

- Definition der Grundgesamtheit
- Stichprobengröße (n)
  - ▶ 200 Sätze aus dem Korpus
  - ▶ 1.000 Reaktionen (von 50 Probanden) im Experiment

- Definition der Grundgesamtheit
- Stichprobengröße (n)
  - ▶ 200 Sätze aus dem Korpus
  - ▶ 1.000 Reaktionen (von 50 Probanden) im Experiment
  - Was sind die elementaren gemessenen Datenpunkte?

- Definition der Grundgesamtheit
- Stichprobengröße (n)
  - 200 Sätze aus dem Korpus
  - ▶ 1.000 Reaktionen (von 50 Probanden) im Experiment
  - Was sind die elementaren gemessenen Datenpunkte?
- Stichprobenmethode

- Definition der Grundgesamtheit
- Stichprobengröße (n)
  - 200 Sätze aus dem Korpus
  - ▶ 1.000 Reaktionen (von 50 Probanden) im Experiment
  - Was sind die elementaren gemessenen Datenpunkte?
- Stichprobenmethode
  - Zufallsstichprobe | Nachweis der uniformen Zufälligkeit

Statistik 02. Deskriptive Statistik

- Definition der Grundgesamtheit
- Stichprobengröße (n)
  - 200 Sätze aus dem Korpus
  - ▶ 1.000 Reaktionen (von 50 Probanden) im Experiment
  - Was sind die elementaren gemessenen Datenpunkte?
- Stichprobenmethode
  - Zufallsstichprobe | Nachweis der uniformen Zufälligkeit
  - Quotenstichprobe | Stratifzierung und Begründung



### Messvariablen und Skalenniveaus

• dichotom/binär | Menge {A, B} | zwei disjunkte Kategorien männlich, weiblich; Präteritum, Perfekt

#### Messvariablen und Skalenniveaus

- dichotom/binär | Menge {A, B} | zwei disjunkte Kategorien männlich, weiblich; Präteritum, Perfekt
- nominal/kategorial | Menge {A, B, ...} | disjunkte Kategorien Parteizugehörigkeit; NP, AP, VP

- dichotom/binär | Menge {A, B} | zwei disjunkte Kategorien männlich, weiblich; Präteritum, Perfekt
- nominal/kategorial | Menge {A, B, ...} | disjunkte Kategorien Parteizugehörigkeit; NP, AP, VP
- ordinal | Tupel ⟨A, B,..⟩, nicht N oder Z | disjunkte Kategorien mit Rang Schulnoten; 5- oder 7-Punkt-Skalen für Akzeptabilität

Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik

- dichotom/binär | Menge {A, B} | zwei disjunkte Kategorien männlich, weiblich; Präteritum, Perfekt
- nominal/kategorial | Menge {A, B, ...} | disjunkte Kategorien Parteizugehörigkeit; NP, AP, VP
- ordinal | Tupel ⟨A, B, ..⟩, nicht N oder Z | disjunkte Kategorien mit Rang Schulnoten; 5- oder 7-Punkt-Skalen für Akzeptabilität
- Verhältnis | +Q<sub>0</sub> | geordnete Werte mit Nullpunkt Temperatur in Kelvin; Lesezeiten

- dichotom/binär | Menge {A, B} | zwei disjunkte Kategorien männlich, weiblich; Präteritum, Perfekt
- nominal/kategorial | Menge {A, B, ...} | disjunkte Kategorien Parteizugehörigkeit: NP. AP. VP
- ordinal | Tupel ⟨A, B, ..⟩, nicht N oder Z | disjunkte Kategorien mit Rang Schulnoten; 5- oder 7-Punkt-Skalen für Akzeptabilität
- Verhältnis | +Q<sub>0</sub> | geordnete Werte mit Nullpunkt Temperatur in Kelvin ; Lesezeiten
- Intervall | 0 | Wie Verhältnis, aber ohne Nullpunkt Temperatur in Celsius

Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik

- dichotom/binär | Menge {A, B} | zwei disjunkte Kategorien männlich, weiblich ; Präteritum, Perfekt
- nominal/kategorial | Menge {A, B, ...} | disjunkte Kategorien Parteizugehörigkeit; NP, AP, VP
- ordinal | Tupel ⟨A, B, ..⟩, nicht N oder Z | disjunkte Kategorien mit Rang Schulnoten; 5- oder 7-Punkt-Skalen für Akzeptabilität
- Verhältnis | +Q<sub>0</sub> | geordnete Werte mit Nullpunkt Temperatur in Kelvin; Lesezeiten
- Intervall | Q | Wie Verhältnis, aber ohne Nullpunkt Temperatur in Celsius
- Zähldaten | Keine beobachtbaren Variablen, sondern Aggregation von dichtotomen, nominalen oder ordinalen Variablen

### Intervalle vs. Verhältnisse

• Verhältnisskala | Größe von Menschen in cm

### Intervalle vs. Verhältnisse

- Verhältnisskala | Größe von Menschen in cm
  - ▶ 200cm = 2 × 100cm usw.

#### Intervalle vs. Verhältnisse

- Verhältnisskala | Größe von Menschen in cm
  - ► 200cm = 2 × 100cm usw.
  - ► Keine Messung unter 0*cm*

- Verhältnisskala | Größe von Menschen in cm
  - ► 200cm = 2 × 100cm usw.
  - Keine Messung unter 0cm
- Intervallskala | Dasselbe als Abweichung vom Mittel

- Verhältnisskala | Größe von Menschen in cm
  - ► 200cm = 2 × 100cm usw.
  - ► Keine Messung unter 0*cm*
- Intervallskala | Dasselbe als Abweichung vom Mittel
  - ► 4cm = 2 × 2cm usw.

- Verhältnisskala | Größe von Menschen in cm
  - ► 200cm = 2 × 100cm usw.
  - ► Keine Messung unter 0cm
- Intervallskala | Dasselbe als Abweichung vom Mittel
  - ► 4cm = 2 × 2cm usw.
  - ► 184cm ≠ 2 × 182cm

- Verhältnisskala | Größe von Menschen in cm
  - ► 200cm = 2 × 100cm usw.
  - Keine Messung unter 0cm
- Intervallskala | Dasselbe als Abweichung vom Mittel
  - ► 4cm = 2 × 2cm usw.
  - ► 184cm ≠ 2 × 182cm
  - Negative Messungen möglich

#### Relevanz der Skalenniveaus

Bestimmung zulässiger mathematischer Operationen

#### Relevanz der Skalenniveaus

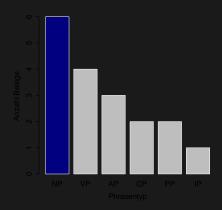
- Bestimmung zulässiger mathematischer Operationen
- Deskriptive Statistiken je nach Skalenniveau

#### Relevanz der Skalenniveaus

- Bestimmung zulässiger mathematischer Operationen
- Deskriptive Statistiken je nach Skalenniveau
- Zulässigkeit von inferenzstatistischen Tests je nach Skalenniveau

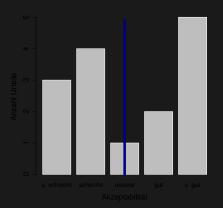


#### Modus | Der häufigste Wert | Alle Skalenniveaus



#### Zentraltendenz II

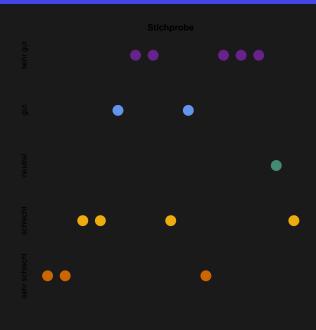
#### Median | Mitte der sortierten Stichprobe | ab Ordinalskala



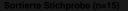
Numerische Messungen | Verschiedene Interpolationsmethoden

https://en.wikipedia.org/wiki/Quantile#Estimating\_quantiles\_from\_a\_sample

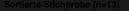
# Median bestimmen | Stichprobe

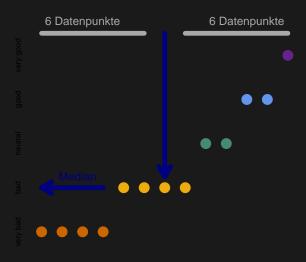


Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik



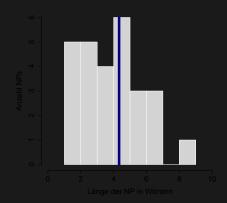






#### Arithmetisches Mittel $\bar{x}$ | Summe aller Werte geteilt durch n | ab Intervallskala

$$\bar{X} = \frac{\sum_{i=1}^{n} x_i}{n}$$



14 / 43

Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik



Dispersion | Streuung der Daten

• Zentraltendenz | Orientierung über Tendenzen der Stichprobe

#### Dispersion | Streuung der Daten

- Zentraltendenz | Orientierung über Tendenzen der Stichprobe
- Ein Maß für Zentraltendenz für beliebig viele Verteilungsformen

#### Dispersion | Streuung der Daten

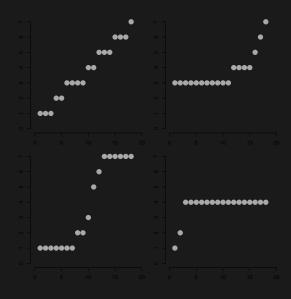
- Zentraltendenz | Orientierung über Tendenzen der Stichprobe
- Ein Maß für Zentraltendenz für beliebig viele Verteilungsformen
- Arithmetisches Mittel | deskriptiv oft unbrauchbar ohne Betrachtung der Verteilung

#### Dispersion | Streuung der Daten

- Zentraltendenz | Orientierung über Tendenzen der Stichprobe
- Ein Maß für Zentraltendenz für beliebig viele Verteilungsformen
- Arithmetisches Mittel | deskriptiv oft unbrauchbar ohne Betrachtung der Verteilung
- Median | auch nur bedingt besser

### Vier sortierte Stichproben

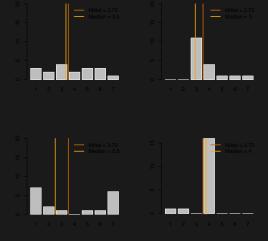
Jeder Punkt entspricht einem Datenpunkt/einer Messung!



### Verteilungsformen

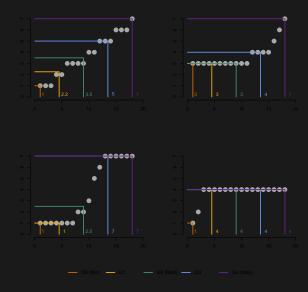
Histogramme | Vier Stichproben mit  $\bar{x}$  = 3.72 und n = 18

Zum Beispiel 18 Bewertungen eines Probanden auf einer 7-Punkt-Skala



#### Quartile

Quartile | Generalisierung des Medians (bei 25 %, 50 %, 75 %)



• Interquartilbereich  $IQR = Q_3 - Q_1$  | Die mittleren 50 %

- Interquartilbereich  $IQR = Q_3 Q_1$  | Die mittleren 50 %
- Boxplots

- Interquartilbereich  $IQR = Q_3 Q_1$  | Die mittleren 50 %
- Boxplots
  - ► Median | Linie in der Mitte

Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik

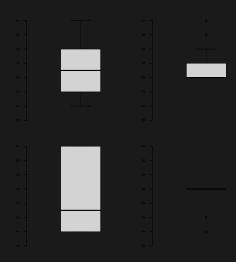
- Interquartilbereich  $IQR = Q_3 Q_1$  | Die mittleren 50 %
- Boxplots
  - ► Median | Linie in der Mitte
  - Oberes und unteres Quartil | Boxen

- Interquartilbereich  $IQR = Q_3 Q_1$  | Die mittleren 50 %
- Boxplots
  - ► Median | Linie in der Mitte
  - ▶ Oberes und unteres Quartil | Boxen
  - ▶ 1,5-facher Interquartilabstand | gestrichelte Hebel

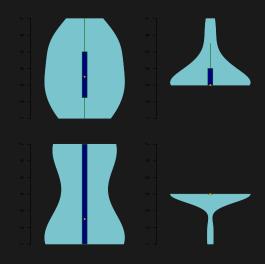
- Interquartilbereich  $IQR = Q_3 Q_1$  | Die mittleren 50 %
- Boxplots
  - ► Median | Linie in der Mitte
  - ▶ Oberes und unteres Quartil | Boxen
  - ▶ 1,5-facher Interquartilabstand | gestrichelte Hebel
  - Ausreißer | Punkte

- Interquartilbereich  $IQR = Q_3 Q_1$  | Die mittleren 50 %
- Boxplots
  - ► Median | Linie in der Mitte
  - ▶ Oberes und unteres Quartil | Boxen
  - ▶ 1,5-facher Interquartilabstand | gestrichelte Hebel
  - Ausreißer | Punkte
- Violinplots | Zusätzlich Plot der Verteilungsdichte (statt Box)

# Boxplots | Die bessere Zusammenfassung

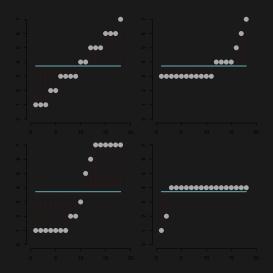


## Violinplots | Die noch bessere Zusammenfassung



#### Was bestimmt die Varianz?

Die Distanzen der Messwerte zum Mittel sind unterschiedlich groß.



## Varianz und Standardabweichung

Varianz s<sup>2</sup> | Quadrierte mittlere Abweichung vom Mittelwert

$$s^{2}(x) = \frac{\sum_{i=1}^{n} (x_{i} - \bar{x})^{2}}{n-1}$$

Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik

## Varianz und Standardabweichung

Varianz s<sup>2</sup> | Quadrierte mittlere Abweichung vom Mittelwert

$$s^{2}(x) = \frac{\sum_{i=1}^{n} (x_{i} - \bar{x})^{2}}{n-1}$$

Standardabweichung s | Quadratwurzel der Varianz

$$s(x) = \sqrt{s^2(x)}$$

## Varianz und Standardabweichung

Varianz s<sup>2</sup> | Quadrierte mittlere Abweichung vom Mittelwert

$$s^{2}(x) = \frac{\sum\limits_{i=1}^{n} (x_{i} - \bar{x})^{2}}{n-1}$$

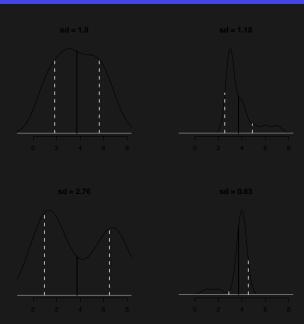
Standardabweichung s | Quadratwurzel der Varianz

$$s(x) = \sqrt{s^2(x)}$$

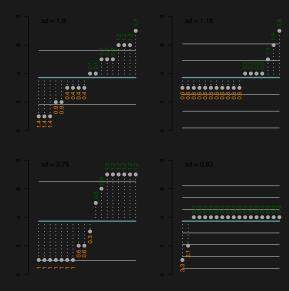
Summe der Quadrate | Zählerterm der Varianz

$$SQ(x) = \sum_{i=1}^{n} (x_i - \bar{x})^2$$

# Unterschiedliche Standardabweichungen



Für jeden Messpunkt  $x_i \mid z_i = \frac{x_i - \bar{x}}{s(x)}$ 



# z-Wert | Rechenbeispiel

• Bsp.: *x* = [3.9, 4.3, 7.2, 8.5, 11.1, 12.1, 14.0, 20.7]

- Bsp.: *x* = [3.9, 4.3, 7.2, 8.5, 11.1, 12.1, 14.0, 20.7]
  - $\bar{x} = 10.225$

$$\bar{x} = 10.225$$

$$s^2(x) = \frac{(3.9-10.255)^2 + ... + (20.7-10.225)^2}{8-1} = \frac{215.495}{7} = 30.785$$

• Bsp.: 
$$x = [3.9, 4.3, 7.2, 8.5, 11.1, 12.1, 14.0, 20.7]$$

$$\bar{x} = 10.225$$

$$s(x) = \sqrt{30.785} = 5.548$$

• Bsp.: 
$$x = [3.9, 4.3, 7.2, 8.5, 11.1, 12.1, 14.0, 20.7]$$

$$\bar{x} = 10.225$$

$$s^2(x) = \frac{(3.9 - 10.255)^2 + ... + (20.7 - 10.225)^2}{8 - 1} = \frac{215.495}{7} = 30.785$$

$$s(x) = \sqrt{30.785} = 5.548$$

$$z = \left[\frac{3.9-10.225}{5.548}, ..., \frac{20.7-10.225}{5.548}\right] = \left[-1.140, -1.068, -0.545, -0.311, 0.158, 0.338, 0.680, 1.888\right]$$

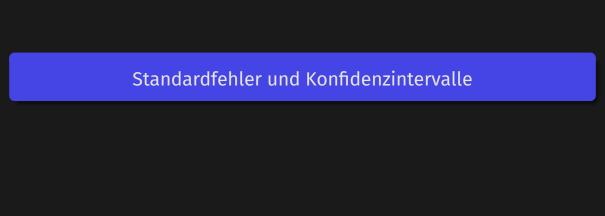


### Zähldaten von zwei Variablen

Kreuztabelle | Darstellung der Zähldaten zweier Variablen

|                     | Variable 1   Wert 1    | Wert2                  |
|---------------------|------------------------|------------------------|
| Variable 2   Wert 1 | Anzahl x <sub>11</sub> | Anzahl x <sub>12</sub> |
| Wert 2              | Anzahl x <sub>21</sub> | Anzahl x <sub>22</sub> |

Roland Schäfer (FSU Jena) Statistik o2. Deskriptive Statistik



• Das Verb essen | Manchmal mit, manchmal ohne Akkusativ (direktes Objekt)

- Das Verb essen | Manchmal mit, manchmal ohne Akkusativ (direktes Objekt)
- Angenommenes wahres Verhältnis | Mit Objekt 39 %, ohne Objekt 61 %

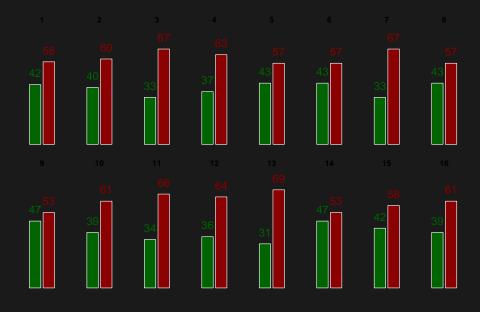
- Das Verb essen | Manchmal mit, manchmal ohne Akkusativ (direktes Objekt)
- Angenommenes wahres Verhältnis | Mit Objekt 39 %, ohne Objekt 61 %
- Viele Stichproben mit n=100 | Ergebnis nicht immer 39 zu 61

- Das Verb essen | Manchmal mit, manchmal ohne Akkusativ (direktes Objekt)
- Angenommenes wahres Verhältnis | Mit Objekt 39 %, ohne Objekt 61 %
- Viele Stichproben mit n=100 | Ergebnis nicht immer 39 zu 61

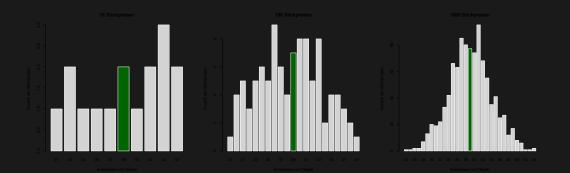
95%-Konfidenzintervall
 In welchem Bereich liegen 95% aller Anteilswerte bei n=100?

Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik

# Sechzehn simulierte Stichprobenentnahmen (n=100)



Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik



• Die meisten  $q \mid$  Nah am wahren Wert Q

- Die meisten  $q \mid Nah am wahren Wert Q$
- Sehr wenige q | Weit von Q entfernt

- Die meisten q | Nah am wahren Wert Q
- Sehr wenige q | Weit von Q entfernt
- Bei unendlich vielen Messungen

- Die meisten q | Nah am wahren Wert Q
- Sehr wenige q | Weit von Q entfernt
- Bei unendlich vielen Messungen
  - ▶ Mittelwert der gemessenen Anteilswerte gleich Q

- Die meisten q | Nah am wahren Wert Q
- Sehr wenige q | Weit von Q entfernt
- Bei unendlich vielen Messungen
  - Mittelwert der gemessenen Anteilswerte gleich Q
  - ► Gemessene Anteilswerte normalverteilt um Q

- Die meisten q | Nah am wahren Wert Q
- Sehr wenige q | Weit von Q entfernt
- Bei unendlich vielen Messungen
  - Mittelwert der gemessenen Anteilswerte gleich Q
  - Gemessene Anteilswerte normalverteilt um Q
  - ► Standardabweichung der Messwerte um Q bekannt → Standardfehler

Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik

- Die meisten q | Nah am wahren Wert Q
- Sehr wenige q | Weit von Q entfernt
- Bei unendlich vielen Messungen
  - Mittelwert der gemessenen Anteilswerte gleich Q
  - Gemessene Anteilswerte normalverteilt um Q
  - ► Standardabweichung der Messwerte um Q bekannt → Standardfehler
- Standardfehler | Standardabweichung der Messwerte

Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik

- Die meisten q | Nah am wahren Wert Q
- Sehr wenige q | Weit von Q entfernt
- Bei unendlich vielen Messungen
  - Mittelwert der gemessenen Anteilswerte gleich Q
  - Gemessene Anteilswerte normalverteilt um Q
  - ► Standardabweichung der Messwerte um Q bekannt → Standardfehler
- Standardfehler | Standardabweichung der Messwerte
  - Bei gegebener Stichprobengröße n

Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik

- Die meisten q | Nah am wahren Wert Q
- Sehr wenige q | Weit von Q entfernt
- Bei unendlich vielen Messungen
  - Mittelwert der gemessenen Anteilswerte gleich Q
  - Gemessene Anteilswerte normalverteilt um Q
  - ► Standardabweichung der Messwerte um Q bekannt → Standardfehler
- Standardfehler | Standardabweichung der Messwerte
  - Bei gegebener Stichprobengröße n
  - Bei einem bekannten Populationsanteil Q

# Standardfehler für Anteilswerte | Berechnung

Für einen wahren Anteilswert O

$$SF(Q, n) = \sqrt{\frac{Q \cdot (1-Q)}{n}}$$

Bsp. für 
$$Q = 0.39$$
 und  $n = 100 \mid SF(q) = \sqrt{\frac{0.39 \cdot (1 - 0.39)}{100}} = 0.0488$ 

Statistik 02. Deskriptive Statistik

# Standardfehler für Anteilswerte | Berechnung

- Für einen wahren Anteilswert Q
- Bei Stichprobengröße n

$$SF(Q, n) = \sqrt{\frac{Q \cdot (1-Q)}{n}}$$

Bsp. für 
$$Q = 0.39$$
 und  $n = 100 \mid SF(q) = \sqrt{\frac{0.39 \cdot (1 - 0.39)}{100}} = 0.0488$ 

Statistik 02. Deskriptive Statistik

# Standardfehler | Interpretation

$$SF(Q, n) = \sqrt{\frac{Q \cdot (1 - Q)}{n}}$$
  
Bsp.:  $SF(0.39, 100) = \sqrt{\frac{0.39 \cdot (1 - 0.39)}{100}} = 0.0488$ 

• Für beliebig viele Stichproben

Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik

# Standardfehler | Interpretation

$$SF(Q, n) = \sqrt{\frac{Q \cdot (1 - Q)}{n}}$$
Bsp.:  $SF(0.39, 100) = \sqrt{\frac{0.39 \cdot (1 - 0.39)}{100}} = 0.0488$ 

- Für beliebig viele Stichproben
- Bei Stichprobengröße n = 100

Statistik 02. Deskriptive Statistik

## Standardfehler | Interpretation

$$SF(Q, n) = \sqrt{\frac{Q \cdot (1 - Q)}{n}}$$
Bsp.:  $SF(0.39, 100) = \sqrt{\frac{0.39 \cdot (1 - 0.39)}{100}} = 0.0488$ 

- Für beliebig viele Stichproben
- Bei Stichprobengröße n = 100
- Aus einer Grundgesamtheit mit wahrem Anteilswert Q = 0.39

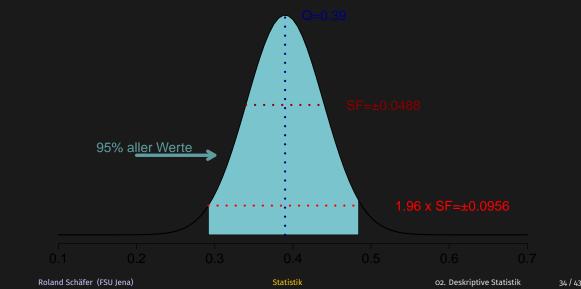
$$SF(Q, n) = \sqrt{\frac{Q \cdot (1 - Q)}{n}}$$
Bsp.:  $SF(0.39, 100) = \sqrt{\frac{0.39 \cdot (1 - 0.39)}{100}} = 0.0488$ 

- Für beliebig viele Stichproben
- Bei Stichprobengröße n = 100
- Aus einer Grundgesamtheit mit wahrem Anteilswert Q = 0.39
- Abweichung der gemessenen Anteile von Q = 0.39 mit einem SF = 0.0488

# Konfidenzintervall | Standardfehler und Normalverteilung

Normal-/Gaussverteilung | Parameter Mittelwert und Standardabweichung

→ Mathematisch exhaustiv bekannt, Flächen unter der Kurve usw. berechenbar



# Verteilungsfunktion der Normalverteilung

Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik

## Verteilungsfunktion der Normalverteilung

$$p(\mathbf{x}) = \frac{1}{\sigma\sqrt{2\pi}}e^{-\frac{1}{2}\left(\frac{\mathbf{x}-\mu}{\sigma}\right)^2}$$

x ist der Wert, für den die Funktion die Wahrscheinlichkeit angibt. Der graue Term skaliert die Verteilung lediglich, damit die Fläche unter der Kurve 1 ist. Der Kern der Funktion ist  $e^{-x^2}$ , weil  $-\mu$  lediglich für die mögliche Verschiebung des Modus von 0 benötigt wird und  $\sigma$  die Spreizung der Verteilung modelliert (größere Standardabweichung bedeutet flachere Kurve). Für den Standardnormalfall kann  $\mu$  = 0 und  $\sigma$  = 1 angesetzt werden.  $\mu$  und  $\sigma$  sind sogenannte Parameter der Funktion.

Falls Sie mehr wissen möchten:

https://youtu.be/cy8r7WSuT1I

Großartiges Video von Grant Sanderson (3blue1brown)

## Konfidenzintervall | z-Werte

• Anteilswerte oder Mittelwerte aus Stichproben (wie erwähnt) normalverteilt

### Konfidenzintervall | z-Werte

- Anteilswerte oder Mittelwerte aus Stichproben (wie erwähnt) normalverteilt
- Der z-Wert, zum Beispiel für α = 0.95: z(0.95) beantwortet:
   Wie viele Standardfehler definieren 95% der Fläche unter der Kurve?

Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik

- Anteilswerte oder Mittelwerte aus Stichproben (wie erwähnt) normalverteilt
- Der z-Wert, zum Beispiel für α = 0.95: z(0.95) beantwortet:
   Wie viele Standardfehler definieren 95% der Fläche unter der Kurve?
- Achtung: Dieser z-Wert ist nicht ganz dasselbe wie der rein deskriptive z-Wert von Folie 25

- Anteilswerte oder Mittelwerte aus Stichproben (wie erwähnt) normalverteilt
- Der z-Wert, zum Beispiel für α = 0.95: z(0.95) beantwortet:
   Wie viele Standardfehler definieren 95% der Fläche unter der Kurve?
- Achtung: Dieser z-Wert ist nicht ganz dasselbe wie der rein deskriptive z-Wert von Folie 25
- Quantilfunktion der Normalverteilung | In R mit qnorm() oder Tabelle

- Anteilswerte oder Mittelwerte aus Stichproben (wie erwähnt) normalverteilt
- Der z-Wert, zum Beispiel für α = 0.95: z(0.95) beantwortet:
   Wie viele Standardfehler definieren 95% der Fläche unter der Kurve?
- Achtung: Dieser z-Wert ist nicht ganz dasselbe wie der rein deskriptive z-Wert von Folie 25
- Quantilfunktion der Normalverteilung | In R mit qnorm() oder Tabelle
- Quantilfunktion | Wie viele Standardabweichungen trennen auf jeder Seite 2.5% ab?

- Anteilswerte oder Mittelwerte aus Stichproben (wie erwähnt) normalverteilt
- Der z-Wert, zum Beispiel für α = 0.95: z(0.95) beantwortet:
   Wie viele Standardfehler definieren 95% der Fläche unter der Kurve?
- Achtung: Dieser z-Wert ist nicht ganz dasselbe wie der rein deskriptive z-Wert von Folie 25
- Quantilfunktion der Normalverteilung | In R mit qnorm() oder Tabelle
- Quantilfunktion | Wie viele Standardabweichungen trennen auf jeder Seite 2.5% ab?
- qnorm(0.025, lower.tail=FALSE)  $\rightarrow z(0.95) = 1.96$

## Konfidenzintervall | Standardfehler um wahren Anteilswert

Standardfehler | Standardabweichung der Stichprobenwerte

$$KI(Q, n, \alpha) = Q \pm z(\alpha) \cdot SF(Q, n)$$

Bsp.:  $KI(0.39, 100, 0.95) = 0.39 \pm 1.96 \cdot 0.0488 = 0.39 \pm 0.096 = [0.29, 0.49]$ 

- Standardfehler | Standardabweichung der Stichprobenwerte
- Konfidenzbreite | z-Wert multipliziert mit Standardfehler

$$KI(Q, n, \alpha) = Q \pm z(\alpha) \cdot SF(Q, n)$$

Bsp.:  $KI(0.39, 100, 0.95) = 0.39 \pm 1.96 \cdot 0.0488 = 0.39 \pm 0.096 = [0.29, 0.49]$ 

- Standardfehler | Standardabweichung der Stichprobenwerte
- Konfidenzbreite | z-Wert multipliziert mit Standardfehler
- 95% der Werte | Intervall Anteilswert ± Konfidenzbreite

$$KI(Q, n, \alpha) = Q \pm z(\alpha) \cdot SF(Q, n)$$

Bsp.:  $KI(0.39, 100, 0.95) = 0.39 \pm 1.96 \cdot 0.0488 = 0.39 \pm 0.096 = [0.29, 0.49]$ 

Statistik 02. Deskriptive Statistik

## Interpretation

Konfidenzintervall im Beispiel | 0.29 bis 0.49

In 95% aller Stichproben mit n = 100 liegt der Messwert zwischen 0.29 und 0.49 bei einem wahren Anteil von 0.39.

Praxis | Wahrer Anteil nicht bekannt, daher Schätzung aus Stichprobenanteil q

In 95% aller Stichproben mit n = 100 liegt der Messwert zwischen 0.29 und 0.49 bei einem wahren Anteil von 0.39.

- Praxis | Wahrer Anteil nicht bekannt, daher Schätzung aus Stichprobenanteil q
- Der gemessene Anteil q kann aber eine totale Fehlschätzung sein!

In 95% aller Stichproben mit *n* = 100 liegt der Messwert zwischen 0.29 und 0.49 bei einem wahren Anteil von 0.39.

- Praxis | Wahrer Anteil nicht bekannt, daher Schätzung aus Stichprobenanteil q
- Der gemessene Anteil q kann aber eine totale Fehlschätzung sein!
- Die Philosophie dahinter geht von wiederholten Messungen aus.

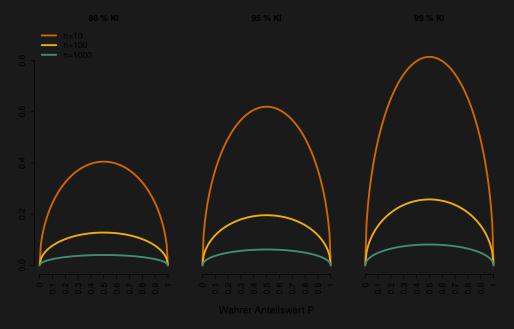
In 95% aller Stichproben mit *n* = 100 liegt der Messwert zwischen 0.29 und 0.49 bei einem wahren Anteil von 0.39.

- Praxis | Wahrer Anteil nicht bekannt, daher Schätzung aus Stichprobenanteil q
- Der gemessene Anteil q kann aber eine totale Fehlschätzung sein!
- Die Philosophie dahinter geht von wiederholten Messungen aus.
- Entweder liegt der gemessene Wert im Konfidenzintervall, oder ein seltenes Ereignis ist eingetreten.

In 95% aller Stichproben mit n = 100 liegt der Messwert zwischen 0.29 und 0.49 bei einem wahren Anteil von 0.39.

- Praxis | Wahrer Anteil nicht bekannt, daher Schätzung aus Stichprobenanteil q
- Der gemessene Anteil *q* kann aber eine totale Fehlschätzung sein!
- Die Philosophie dahinter geht von wiederholten Messungen aus.
- Entweder liegt der gemessene Wert im Konfidenzintervall, oder ein seltenes Ereignis ist eingetreten.
- Falsche Interpretation:
   Wir sind zu 95% sicher, dass der wahre Wert zwischen 0.29 und 0.49 liegt.

# Konfidenzintervall | Breite bei verschiedenen Q, n und $\alpha$



Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik

Roland Schäfer (FSU Jena) Statistik 02. Deskriptive Statistik

Parallel zum KI für Anteilswerte: KI für Mittelwerte mit derselben Formel

Parallel zum KI für Anteilswerte: KI für Mittelwerte mit derselben Formel

Nur der Standardfehler wird anders berechnet:

$$SF(\sigma, n) = \frac{\sigma}{\sqrt{n}}$$

$$KI(\bar{x}, n, \alpha) = \bar{x} \pm z(\alpha) \cdot SF(\sigma, n)$$

Parallel zum KI für Anteilswerte: KI für Mittelwerte mit derselben Formel

Nur der Standardfehler wird anders berechnet:

$$SF(\sigma, n) = \frac{\sigma}{\sqrt{n}}$$

$$KI(\bar{x}, n, \alpha) = \bar{x} \pm z(\alpha) \cdot SF(\sigma, n)$$

Interpretation des KI (95%): Für einen beliebigen Mittelwert  $\bar{x}$  und die wahre Standardabweichung der Population  $\sigma$  liegen im Grenzwert exakt 95% aller Stichproben der Größe n im 95%-KI.

Hier wird die wahre Standardabweichung  $\sigma$  ggf. aus der Standardabweichung s(x) Stichprobe geschätzt.

# Zur Interpretation des KIs

## Zur Interpretation des KIs

Schauen Sie sich möglichst mein (sehr altes) Video zur Interpretation von KIs an, auch wenn ich deutlich weniger im Kopf habe als Grant Sanderson.

https://www.youtube.com/watch?v=TG8Z3RXL4E8X

| α    | z(a)  | α    | z(a)  |
|------|-------|------|-------|
| 0.99 | 2.576 | 0.84 | 1.405 |
| 0.98 | 2.326 | 0.83 | 1.372 |
| 0.97 | 2.170 | 0.82 | 1.341 |
| 0.96 | 2.054 | 0.81 | 1.311 |
| 0.95 | 1.960 | 0.80 | 1.282 |
| 0.94 | 1.881 | 0.79 | 1.254 |
| 0.93 | 1.812 | 0.78 | 1.227 |
| 0.92 | 1.751 | 0.77 | 1.200 |
| 0.91 | 1.695 | 0.76 | 1.175 |
| 0.90 | 1.645 | 0.75 | 1.150 |
| 0.89 | 1.598 |      |       |
| 0.88 | 1.555 |      |       |
| 0.87 | 1.514 |      |       |
| 0.86 | 1.476 |      |       |
| 0.85 | 1.440 |      |       |



### Einzelthemen

- Inferenz
- Deskriptive Statistik
- Nichtparametrische Verfahren
- z-Test und t-Test
- 5 ANOVA
- Freiheitsgrade und Effektstärken
- Power und Severity
- 8 Lineare Modelle
- Generalisierte Lineare Modelle
- o Gemischte Modelle

#### Literatur I

Bortz, Jürgen & Christof Schuster. 2010. Statistik für Human- und Sozialwissenschaftler. 7. Aufl. Berlin: Springer.

Gravetter, Frederick J. & Larry B. Wallnau. 2007. Statistics for the Behavioral Sciences. 7. Aufl. Belmont: Thomson.

#### **Autor**

#### Kontakt

Prof. Dr. Roland Schäfer Institut für Germanistische Sprachwissenschaft Friedrich-Schiller-Universität Jena Fürstengraben 30 07743 Jena

https://rolandschaefer.net roland.schaefer@uni-jena.de

### Lizenz

#### Creative Commons BY-SA-3.0-DE

Dieses Werk ist unter einer Creative Commons Lizenz vom Typ Namensnennung - Weitergabe unter gleichen Bedingungen 3.0 Deutschland zugänglich. Um eine Kopie dieser Lizenz einzusehen, konsultieren Sie

http://creativecommons.org/licenses/by-sa/3.0/de/ oder wenden Sie sich brieflich an Creative Commons, Postfach 1866, Mountain View, California, 94042, USA.